基于MLLM的内容安全审核平台

课后作业

- 把单图的数据不过滤跑下效果
- 改prompt和不改prompt看它们之间的效果差异性
- 不改prompt会不会报错
- 把单图复制一份就不需要改prompt看下效果如何

项目介绍

背景介绍

- 内容审核是目前互联网大厂必不可少的很重要的一部分，不管是对于哪个大厂都需要一个这样的部门来对平台的内容进行质量的审核，随着AI技术的不断发展，目前大模型技术在内容审核平台是很重要的一个应用落地场景，之前通过人工的方式对其进行审核，现在可以通过AI的技术审核可以大幅的提升整体审核的效率，同时可以降低企业的人工成本，**目前也是大模型在互联网企业落地的很重要的一个业务**
- 上述项目过程中的亮点在于**多场景的任务混合训练+强化学习**在审核任务中的落地，具体来说

- To c：快手、抖音，12点抖音，
- To b：阿里，pdd，电商，
- 开店审核：营业执照、身份证、个人头像、姓名，身份证号码， 10多个点

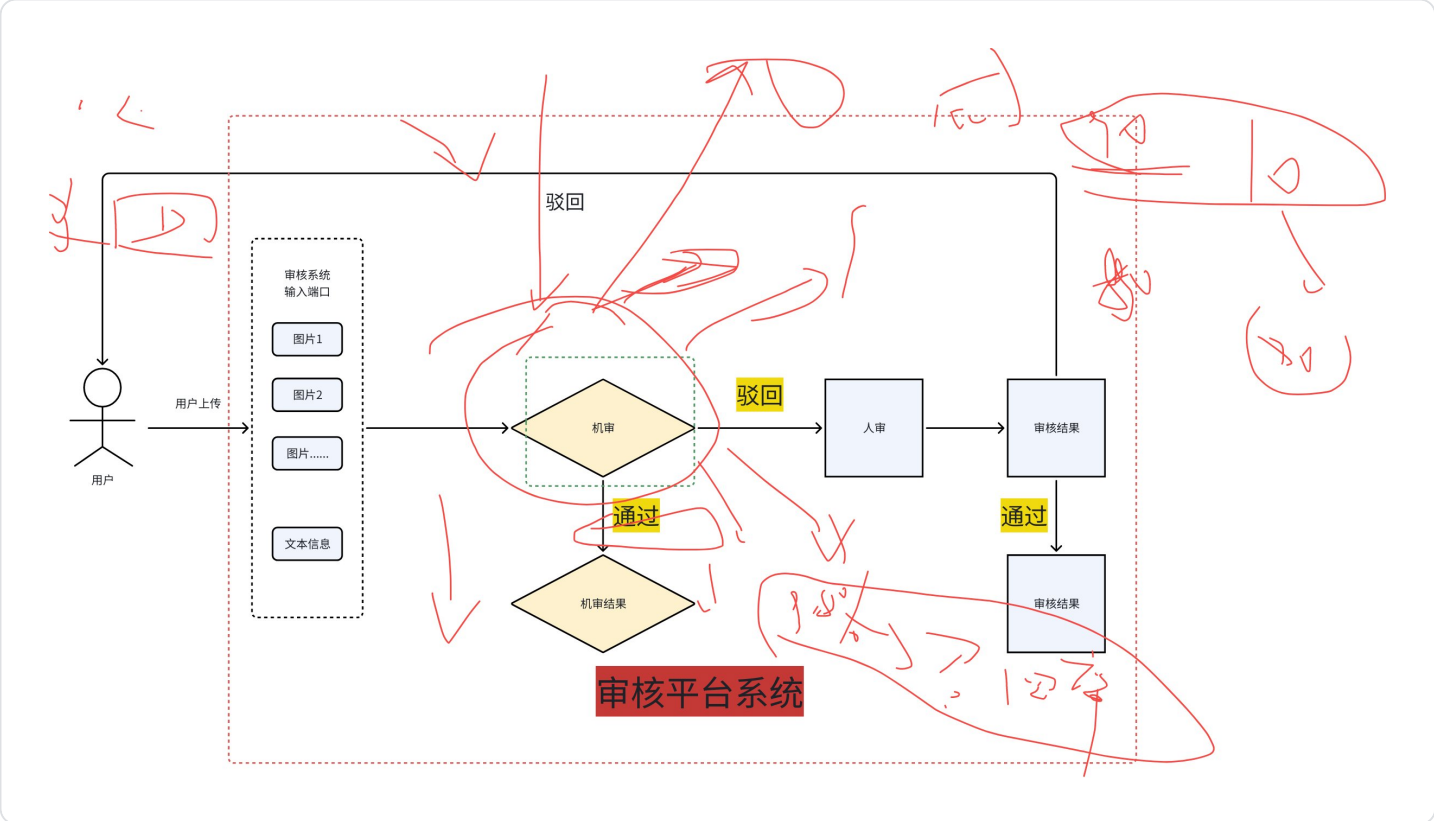

业务理解

- 风控业务：信贷业务，牺牲一部分放贷人，也不想用户逾期还款，
- 审核目标：降本提效，降低人工审核的量，提升审核的速度
- 图片是否ps审核：技术指标应该用什么？精确率
- 准召平衡
- 分类任务：准确率：对的/总的，100,90个是男的，10个女的，
- 精确率：
- 召回率：
- 技术指标：提升机审通过的精确率，再此基础上尽可能得提升机审的召回率

技术方案

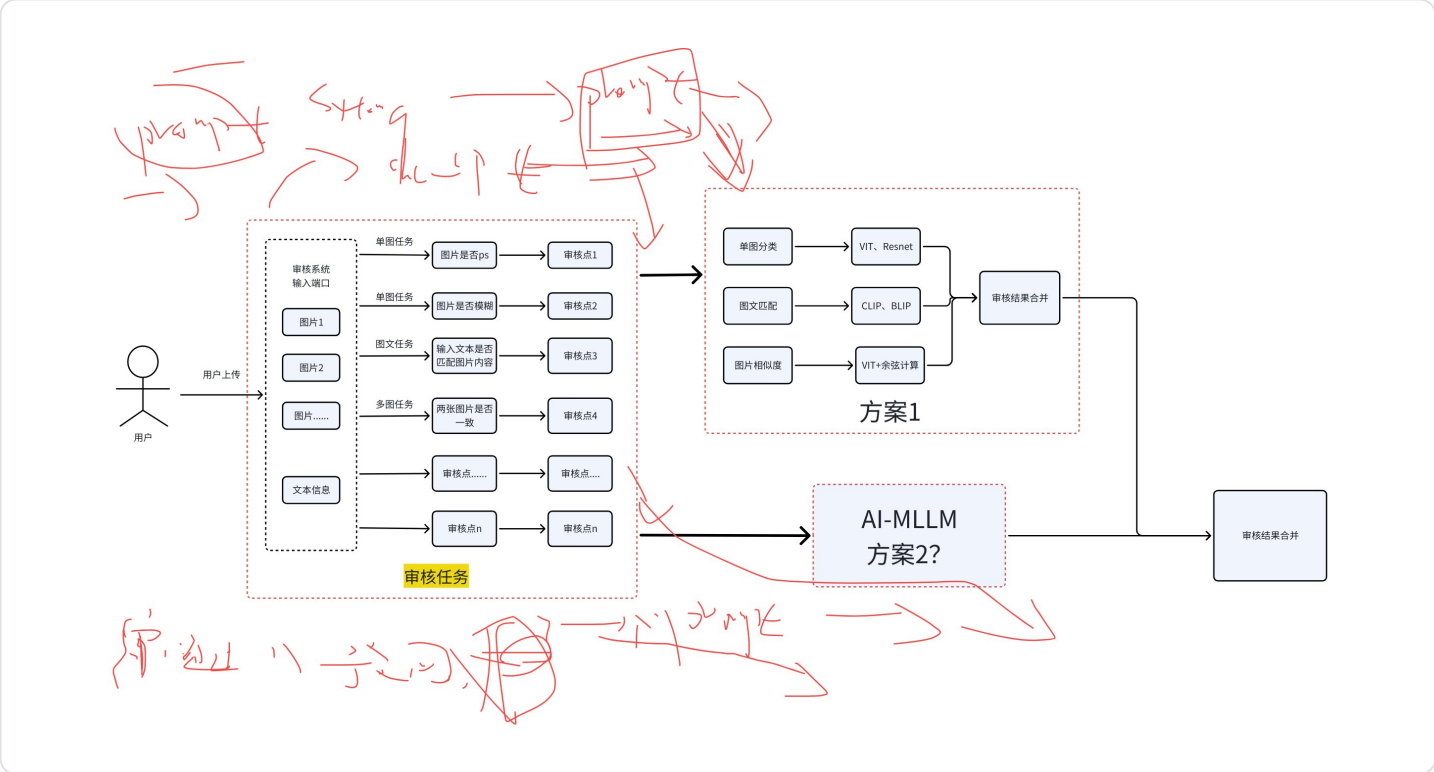

方案对比

方案	优点	缺点
方案1	• 资源消耗小 • Qa •	• 工程复杂，效果可能一般 • 分阶段执行，迭代某一个模块会影响整体结果 • 后期迭代、维护比较费劲 • 能力可复用性不太强
方案2	• Prompt方式 🏖️ • 把所有任务合并到一个prompt • 每个任务一个prompt • 微调方式 ✍️ • 目标：审核原因+审核结果+审核的标签 • label：《think》 思考过程 《\think》 <answer> 结果 </answer> • Reward： 格式奖励+结果奖励+标签简历+思考过滤的长度奖励 • 强化学习grpo：\think 思考过程 \think，<answer> 结果 </answer>	

	• Deepseek r1模型的训练流程，目标：《\think》 思考过程 《\think》， <answer> 结果 </answer>， Base model v3-》**冷启动sft**》grpo训练， pt，sft deepseek v3版本模型 - > 模型拥有初步回答思考的能力-> qa • {图片清晰度识别：<think> 思考过程</think> <anser> 通过</anser>；人像一致性审核：驳回，图片中两个人物不一致；关键信息匹配：驳回，输入姓名与身份证不一致}	
数据优化	• 每个场景抽取k条驳回数据集，1.2w数据集 • 40多条驳回样本 • 概率输出：用传统机器学习，或者bert，输出概率值，	• X + xa -》 y • X -》 xa+y

方案2技术细节

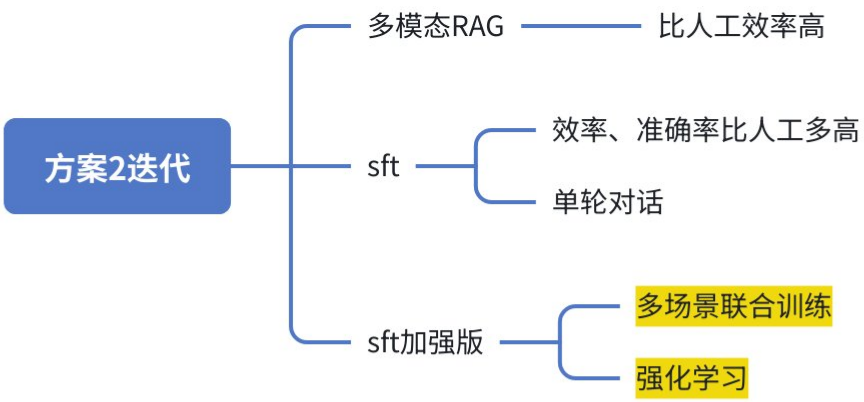

- 输入数据：图片：个人身份证、营业执照、个人自拍照， 文本：个人姓名、身份证号码、营业执照号
- 输出审核结果：1. 判断图片是否有ps痕迹；2. 图片是否清晰； 3. 两张图片里面的人是否是一个人； 4. 输入的姓名和身份证上面的名字是否一致； 5. 输入的营业执照和图片的号码是否一致。。。。。

- 把输出结果转变成一个json格式，json格式中的key就是审核点，value就是审核结果
- 下面简单介绍一个互联网各个大厂的内容审核平台的整体流程框架，具体如下所示：

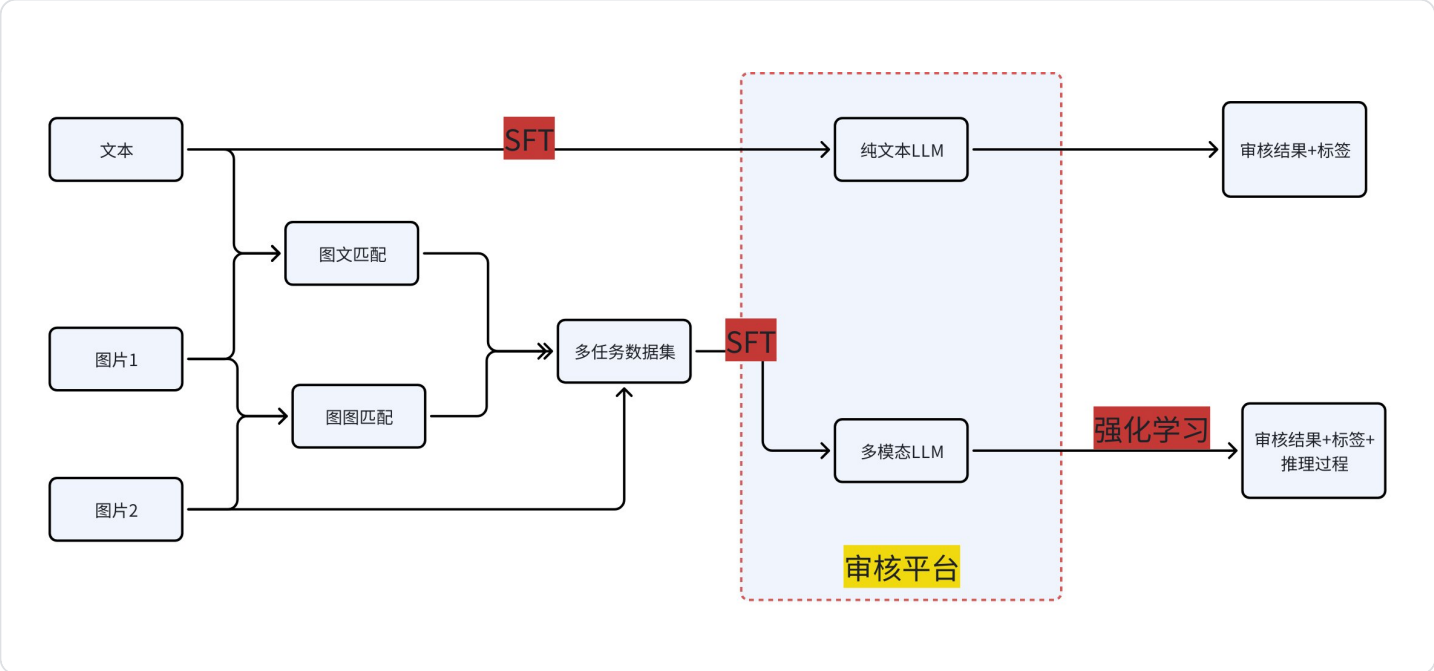

- 本次介绍AI在多模输入场景下的AI审核算法框架流程图如下所示：

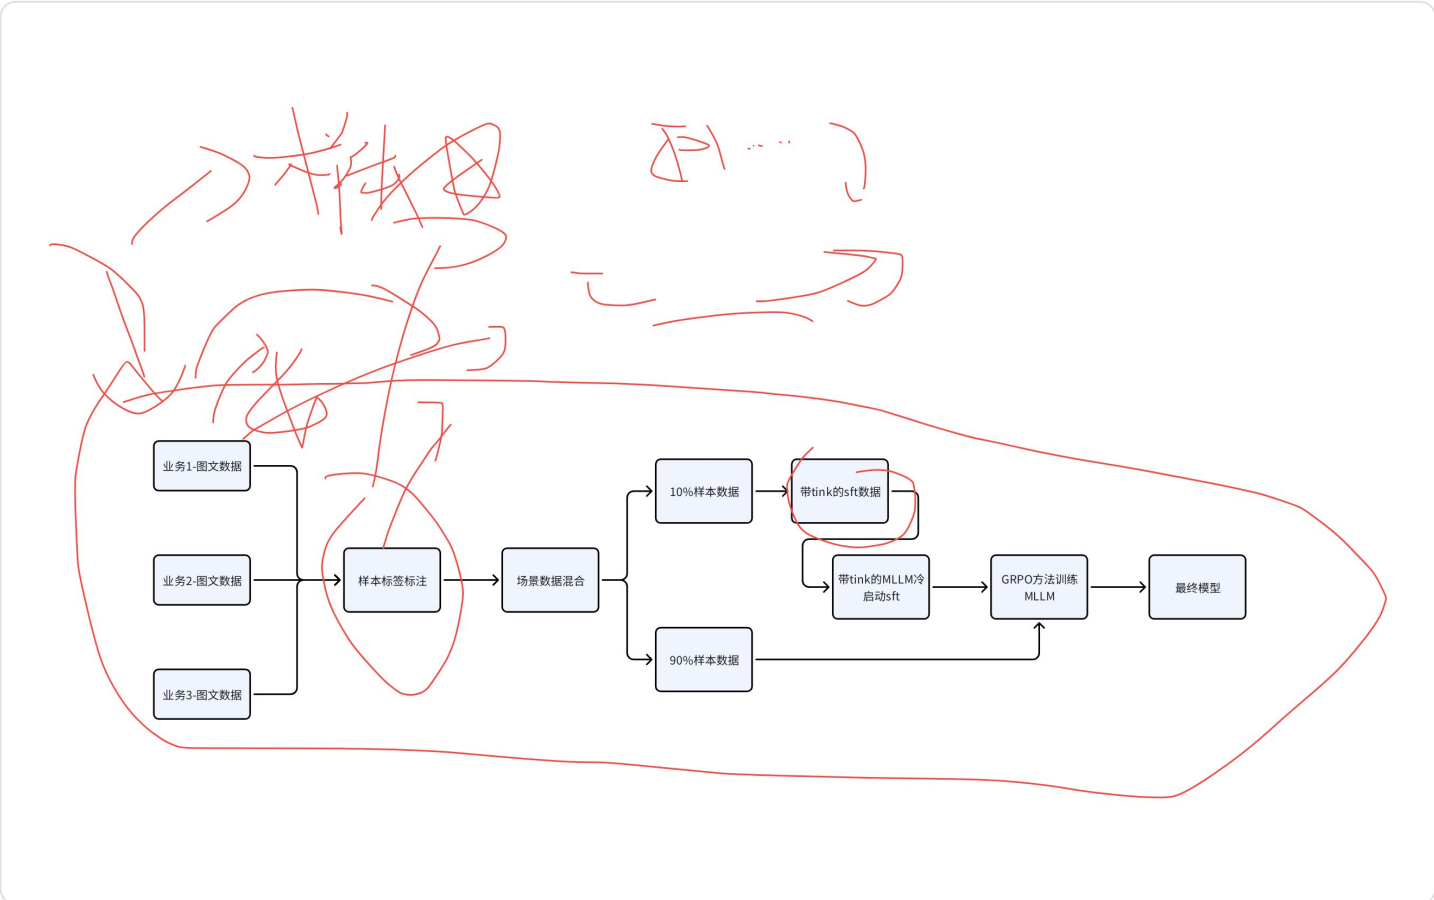

数据集介绍

brand_new.zip
259.86MB

charge_new.zip
310.12MB

data.csv
21.43KB

audit_data_process (1).ipynb
76.27KB

代码介绍

- 本次项目中的代码主要为lora的微调代码，具体的代码如下所示：

run.sh
603 B

train_lora.py
10.74KB

- 当然如果大家不需要对模型进行改进，也可以通过swift框架进行微调训练
- 对于grpo的训练目前有很多框架支持训练，有swift框架，verl框架，R1-v框架GitHub - Deep-Agent/R1-V: Witness the aha moment of VLM with less than $3.

项目总结

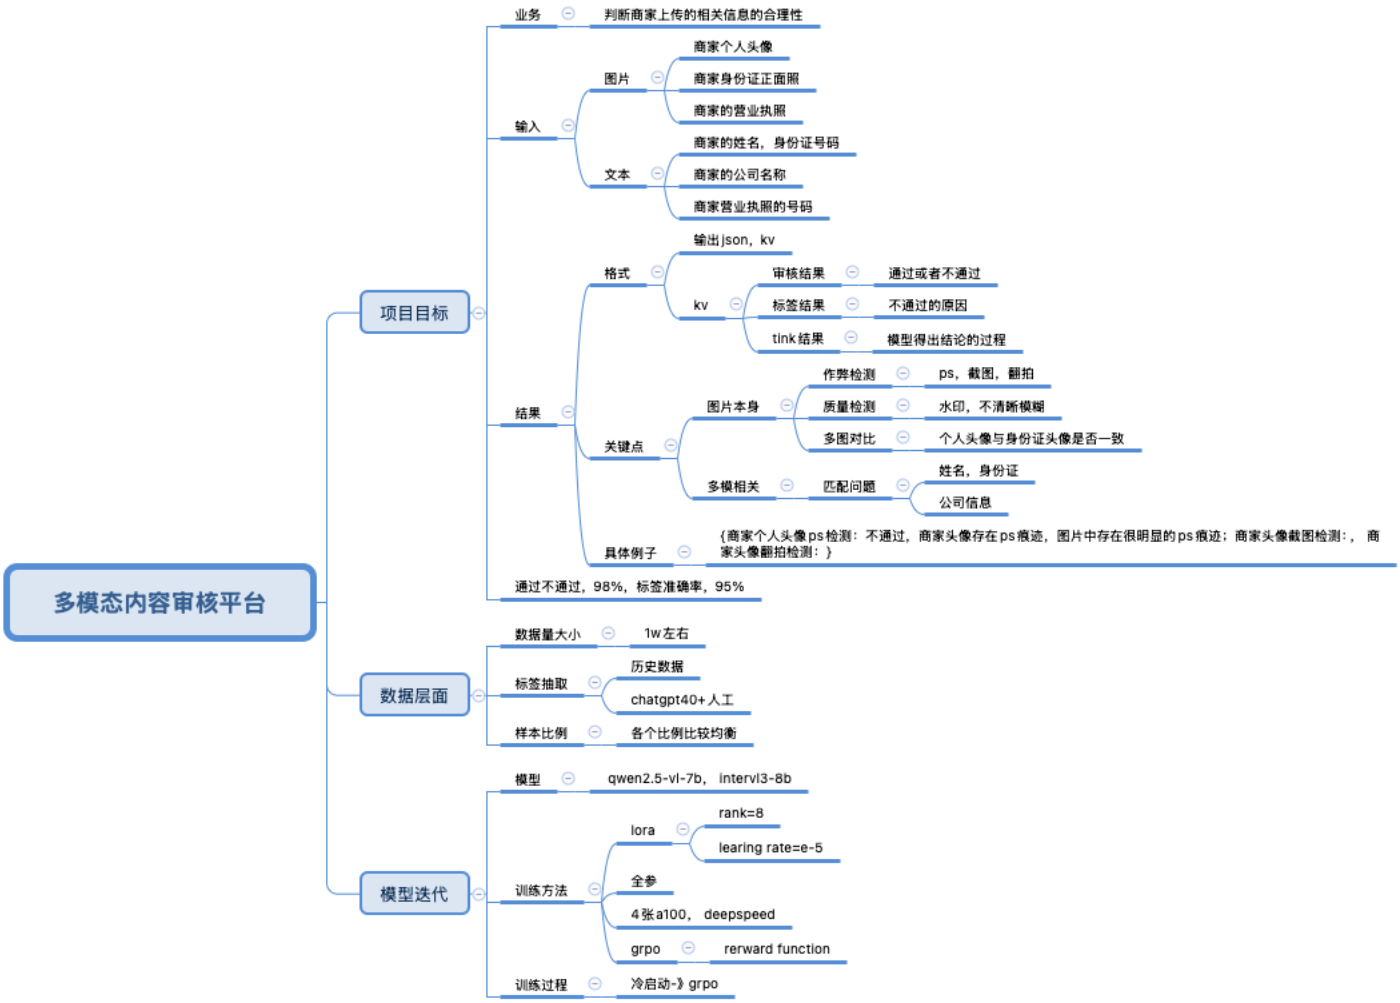

简历项目

数据处理

- 通过Pyhton分析各个审核点数据的正负比例的平衡；通过Chatgpt 4o构建Prompt提取审核不通过的驳回标签；
- 针对样本不平衡的审核点、对于单图、多图、图文审核点通过裁剪、旋转、真实场景的采集、以及随机修改相关的文本数据来构建驳回数据集来平衡通过与驳回比例，最终获取1.5W+的均衡训练数据集；

多模态大模型内容理解

- 基于Qwen2.5-7B-VL、GLM-4v、InternVL系列模型对构建的单轮的包括单图、多图、图文多种类型的混合带通过|驳回、以及驳回标签的数据集，通过多卡加上Deepseed加速的Lora微调方式以及通过调整学习率、batch size、epoch等参数使得最终模型在各个审核通过|驳回的精确率达到95%，召回率达到70%；审核驳回标签的准确率达到90%；

- 为了适配业务的审核自动化需求，通过调整MLLM的token预测概率值，是的最终精确率达到98%的情况下，召回率达到60%；

强化学习

- 为了提升整体审核的召回率，同时方便业务更好提升审核的效率，通过构建Prompt蒸馏GLM4.5-v多模态大模型针对训练数据集中的15%的训练样本构建长度在30字以内的审核原因来作为整合强化学习的冷启动数据集；
- 针对冷启动数据集通过Qwen2.5-VL-7B模型进行冷启动训练，使得模型能够输出带审核原因、审核标签、审核结果的base多模态审核大模型，同时在测试数据集上，审核结果和审核标签与全量sft模型效果低5%；
- 为了进一步使得冷启动训练完的多模态大模型的审核准确率，将剩下的85%的审核数据集通过GRPO对其进行训练，并构建基于格式+审核标签+审核结果的混合奖励模型，最终多模态审核大模型的各个场景的审核精确率达到97%，召回率85%；审核驳回标签的准确率达到94%；

一、基于 MLLM 的信息审核系统

项目背景：针对到家事业部个人报销平台原有审核流程依赖人工与浅层模型、存在准确率不足与效率低下的问题， 主导构建了基于多模态大模型的智能信息审核系统。 通过引入端到端的多模态理解与推理能力， 重构审核链路， 显著提升审核准确性、自动化水平与处理效率；

核心工作：

☒ 数据治理与样本构建：对包含编号、姓名、金额等个人或部门信息的小程序截图以及发票、个人与门店合照图片数据进行清洗与标准化。 基于多图文输入场景， 利用 GPT-4o 多模态能力进行 Zero-shot 样本标签抽取， 构建结构化微调指令数据集， 支持字段一致性比对、图片质量与篡改检测， 输出标准化 Json 判断结果；

☒ 模型选择与微调：在 4 * A100 环境下， 系统对比 Qwen2.5-VL-7B-Instruct、Intern-VL、GLM-VL 等主流模型，通过 ZeRO1 LoRA 策略进行高效微调， 并优化数据类别分布、学习率及 batch 内样本比例， 提升模型在审核任务上的适应性与稳定性；

☒ 强化学习优化推理与解释性： 为进一步提升分类效果并增强结果可解释性， 设计少量思维链样本对模型进行冷启动微调， 并结合多规则奖励函数进行 GRPO 强化学习训练， 有效提升模型在复杂场景下的推理能力与驳回理由生成的合理性。

项目成果：从季度数据中重新采样 1K+ 收据记录进行测试， 识别分类准确率提升 16 个百分点 (81% → 97%), 标签准确率提升 15 个百分点 (78% → 93%), 审核效率与自动化水平显著提高， 为业务规模化审核落地提供可靠算法支撑。

二、基于 MLLM 的地址检索系统

项目背景：针对配送事业部跑腿业务中用户需手动填写订单口令与地址、导致操作烦琐且耗时较长的痛点， 主导设计了基于多模态大模型的地址智能识别与推荐系统。 该系统支持用户通过上传订单图片自动提取关键信息并智能推荐地址， 有效简化下单流程， 提升下单效率与用户体验。

核心工作：

☒ 多模态样本构建与标注： 围绕餐饮、鲜花、快递等多元业务场景， 构造涵盖口令、地址、门店、品牌及类别的多场景混合数据集。 采用 Qwen-VL 系列模型结合 Prompt 技术进行初步标注， 再经人工校验确保质量， 最终完成 1 万+ 高质量训练样本的构建；

☒ 多模态模型训练与优化： 基于 GLM-4V、Qwen-VL 等模型， 通过调整场景数据分布、样本质量、训练参数及微调策略 (LoRA/全参数、单轮/多轮对话设计）, 持续迭代优化模型。 最终实现关键信息识别准确率达 99.8%, 分类准确率达 98%；

☒ 地址检索策略升级： 以模型识别出的口令地址与品牌分类为基础， 设计多维度 query 组合检索策略， 将地址检索的召回率提升80%, 准确率提升 5%, 显著增强地址匹配的覆盖与精度。